PROYECTO INTEGRADOR: CONSULTORÍA DE BUSINESS INTELLIGENCE

Etapas 1 y 2 · Análisis de Ventas en una Empresa de E-Commerce

Entidad de Formación: Programa BI Consulting – Talento Tech | GCBA
Consultora: Datawise Consulting
Rol: Analista de Business Intelligence
Alumno: Ruben Barrios
Instancia de Evaluación: Pre-Entrega de Proyecto (Clases 1 a 8)
Fecha de Presentación: Octubre 2024 / Ciclo 2026

Archivos del Entregable: 📁 Google Drive (Sheets en Vivo) ↗ `Excel/Sheets: TPI_BI_Consulting_Ventas_Ecommerce.xlsx` `PDF: INFORME_PRE_ENTREGA_BI_CONSULTING.pdf` `ventas.csv` `clientes.csv` `productos.csv` `categorias.csv` `metodos_pago.csv`

1. CAPTACIÓN DEL CLIENTE: LA IMPORTANCIA DE BUSINESS INTELLIGENCE EN E-COMMERCE

1.1. Contexto y Diagnóstico del Negocio

En el entorno competitivo del comercio electrónico actual, las empresas minoristas se enfrentan a un volumen masivo y continuo de microtransacciones generadas a través de múltiples puntos de contacto digitales. Sin embargo, acumular datos no es equivalente a generar valor. En muchas organizaciones, estos datos permanecen dispersos en hojas de cálculo desarticuladas, pasarelas de pago y registros de stock, creando **silos de información** que imposibilitan una comprensión integral del rendimiento del negocio.

Sin una práctica formal de Business Intelligence (BI), la toma de decisiones se apoya en la intuición o en reportes retroactivos estáticos que toman días en consolidarse. Esto conlleva ineficiencias críticas: sobrecostos por rotura o exceso de stock, incapacidad para identificar a los clientes más valiosos, desconocimiento de la fricción en las pasarelas de cobro y falta de visibilidad sobre los márgenes reales por categoría de producto.

1.2. Propuesta de Valor y Beneficios Directos de BI

La implementación de metodologías y herramientas de Business Intelligence transforma estos datos transaccionales en **activos estratégicos para la toma de decisiones basada en evidencia**:

1. **Visibilidad Centralizada en Tiempo Real:** Centraliza en una única fuente de la verdad (*Single Source of Truth*) el comportamiento de ventas, inventario y clientes, reduciendo los tiempos de elaboración de informes de semanas a minutos.
2. **Optimización de Inventario y Rotación por Categoría:** Permite cruzar el volumen de ventas con el stock disponible, identificando qué líneas de alta demanda (como *Carnicería* o *Lácteos*) requieren reposición ágil frente a líneas de rotación más baja (*Conservas*).
3. **Comprensión del Comportamiento del Consumidor:** Segmentación por ticket promedio, frecuencia de compra y ubicación geográfica, habilitando el diseño de campañas comerciales dirigidas y promociones personalizadas.
4. **Eficiencia en Medios de Pago y Cobranza:** Diagnóstico de la adopción de billeteras digitales (Mercado Pago), transferencias bancarias y tarjetas, permitiendo monitorear pedidos pendientes y mitigar cancelaciones.
5. **Mitigación de Riesgos y Control Operativo:** Seguimiento en tiempo real de transacciones canceladas y pendientes antes de que afecten la satisfacción del cliente o la liquidez del negocio.

1.3. Ecosistema de Herramientas y Metodología Aplicada

Para este proyecto de consultoría, se implementa una solución ágil y accesible alineada al ecosistema de Google:

- **Google Sheets (Capa de Recolección, Limpieza, Modelado y Análisis):** Auditoría inicial con checklists estructurados; saneamiento y uniformización de textos con funciones nativas (`ESPACIOS` , `NOMPROPIO` , `MINUSC`); normalización de datos numéricos (`VALOR` , `SUSTITUIR`); integración relacional de tablas con `BUSCARV` ; y cálculo de métricas estadísticas descriptivas (`PROMEDIO` , `MEDIANA` , `MODA.UNO` , `DESVEST.M`).
- **Looker Studio (Capa de Reportería Interactiva y Presentación Gerencial):** Conexión directa a las hojas normalizadas de Google Sheets para diseñar tableros dinámicos, facilitando el autoservicio de información a la dirección sin barreras técnicas.

2. INVESTIGACIÓN: CONTEXTO ÉTICO Y LEGAL EN EL MANEJO DE DATOS EN E-COMMERCE

2.1. Selección del Caso de Estudio: Sanción Récord del GDPR a Amazon (€746 Millones, 2021)

El comercio electrónico procesa continuamente datos personales sensibles (nombres, domicilios de entrega, números telefónicos, correos electrónicos, historiales de navegación y hábitos de gasto). El límite entre la personalización de la experiencia de compra y la invasión a la privacidad del consumidor es crítico.

En julio de 2021, la Comisión Nacional de Protección de Datos de Luxemburgo (CNPD), autoridad líder en la Unión Europea bajo el Reglamento General de Protección de Datos (**GDPR**), impuso una sanción histórica de **746 millones de euros a Amazon Europe Core S.à r.l.**

2.2. Contexto de la Infracción y Faltas a la Ética

El caso se originó a partir de una investigación impulsada por la ONG de derechos digitales *La Quadrature du Net*, representando a más de 10.000 ciudadanos. Los hallazgos revelaron:

1. **Perfilado Publicitario Invasivo sin Consentimiento Válido:** Amazon rastreaba los patrones de navegación, búsquedas y compras de los usuarios para construir perfiles conductuales altamente detallados, utilizándolos en publicidad dirigida sin contar con un consentimiento libre, previo e informado (infracción al Art. 6 del GDPR).
2. **Opacidad en el Tratamiento de Datos:** La empresa no informaba con claridad cómo se combinaban los datos transaccionales con los sistemas de publicidad interna (*Amazon Advertising*), impidiendo que los usuarios ejercieran sus derechos de acceso, oposición y supresión (Arts. 12 y 13 del GDPR).
3. **Uso de Patrones Oscuros (*Dark Patterns*):** Las plataformas digitales estaban diseñadas para inducir a los usuarios a aceptar el rastreo, dificultando deliberadamente la opción de rechazar las cookies publicitarias.

2.3. Consecuencias Comerciales, Legales y Reputacionales

- **Sanción Económica Récord:** Constituyó la mayor multa por privacidad impuesta en la Unión Europea hasta esa fecha, sentando un precedente judicial ineludible para gigantes tecnológicos.
- **Obligación de Rediseño Estructural:** Amazon debió modificar sus avisos de privacidad y sus mecanismos de consentimiento en toda Europa, permitiendo rechazo de cookies en un solo clic.
- **Pérdida de Confianza del Consumidor:** El caso fortaleció el reclamo global de los consumidores por una mayor soberanía sobre sus datos personales, impulsando regulaciones similares en América (como la ley **CCPA** de California y normativas locales de protección de datos).

2.4. Lecciones Aprendidas y Principios de Privacidad para Nuestro Proyecto

Para la práctica de consultoría en este e-commerce, se adoptan los siguientes estándares éticos y directrices de gobernanza:

1. **Privacidad por Diseño y por Defecto (*Privacy by Design*):** Recolectar únicamente los datos indispensables para cumplir la transacción comercial.
2. **Principio de Minimización:** En los informes de gestión y tableros compartidos, no exponer datos sensibles innecesarios (como correos o teléfonos), empleando identificadores anonimizados o pseudonimizados (`ID_Cliente`).
3. **Transparencia y Gestión del Consentimiento:** Respetar la voluntad del usuario si solicita darse de baja o eliminar su cuenta de la base de clientes.
4. **Seguridad y Control de Accesos:** Al utilizar herramientas colaborativas en la nube como Google Sheets y Google Drive, restringir los permisos mediante roles definidos (solo lectura para usuarios generales, edición restringida al equipo autorizado).

> **Conclusión Ética:** La analítica de datos en comercio electrónico debe balancear la rentabilidad comercial con el respeto irrestricto a los derechos digitales de los consumidores, garantizando trazabilidad y confidencialidad en cada fase del ciclo de vida del dato.

3. INVESTIGACIÓN: EXPLORACIÓN Y BÚSQUEDA DE FUENTES DE DATOS PÚBLICAS

Para contrastar el desempeño de este e-commerce con patrones de mercado del comercio electrónico global y regional, se identificaron y analizaron **tres fuentes de datos públicas abiertas** con alto potencial analítico:

N°	Nombre de la Fuente	Organización / Entidad	Enlace de Acceso	Tipos de Datos y Estructura	Potencial Analítico para E-commerce
1	**Digital Economy and Society: E-commerce Statistics**	Eurostat (Oficina Europea de Estadística - Comisión Europea)	Eurostat Data Portal	Series de tiempo tabulares e indicadores multidimensionales (CSV, TSV, SDMX, API REST). Métricas sobre ventas B2C/B2B, porcentaje de compradores digitales (*e-shoppers*), frecuencia de compra y medios de pago.	**Benchmark internacional de penetración digital:** Permite contrastar la adopción de billeteras electrónicas frente a tarjetas y evaluar la tasa de penetración de compras online contra un estándar de referencia supranacional.
2	**Monthly & Quarterly Retail E-Commerce Sales (E-Stats)**	U.S. Census Bureau (Oficina del Censo de los EE.UU.)	Census Bureau E-Stats	Series temporales agregadas (XLSX, CSV, API pública). Datos mensuales y trimestrales de ventas minoristas desglosados en canal físico tradicional vs. comercio electrónico.	**Análisis macroeconómico y estacionalidad:** Facilita medir la cuota de mercado del canal digital (*penetration rate*) y calibrar picos de demanda estacionales (eventos de descuento, fin de año, liquidaciones).
3	**Online Retail II Data Set**	UCI Machine Learning Repository (University of California, Irvine)	UCI Dataset Repository	Transaccional no agregado (más de 1.000.000 de registros en Excel/CSV de un retail minorista británico con ID cliente, ítem, fecha, cantidad y precio).	**Modelado de Clientes y Canasta:** Ideal para ejecutar segmentación avanzada mediante metodología **RFM** (Recencia, Frecuencia, Valor) y minería de reglas de asociación (*Market Basket Analysis*) para venta cruzada.

Síntesis de Aplicación Práctica al Negocio

La combinación de estas tres fuentes externas complementa el análisis transaccional interno de la compañía:

- **Nivel Macro (Census / Eurostat):** Permite situar el crecimiento del negocio en el contexto macroeconómico, verificando si las variaciones mensuales responden a tendencias generales del mercado minorista.
- **Nivel Micro (UCI Online Retail II):** Proporciona una base metodológica probada para clustering de clientes, reglas de recomendación de productos y estimación del ciclo de vida del comprador (LTV).

> **Estrategia de Enriquecimiento:** Estas fuentes abiertas sientan las bases para las Etapas 3 y 4 del proyecto final, donde se incorporarán análisis predictivos de series de tiempo y modelos de clasificación sobre los clientes del e-commerce.

4. STATUS DE CALIDAD DE LOS DATOS (DATA QUALITY CHECKLIST)

4.1. Marco de Evaluación Aplicado (Clase 4)

En cumplimiento de la actividad práctica de la Clase 4, se auditó el conjunto completo de datos compuesto por: `ventas.csv`, `clientes.csv`, `productos.csv`, `categorias.csv` y `metodos_pago.csv`. Se evaluaron los 6 criterios fundamentales de calidad de la información:

4.2. Registro Consolidado de Hallazgos y Diagnóstico

Criterio	Archivo / Tabla	Variable Evaluada	Hallazgo Diagnóstico	Riesgo	Acción Correctiva	Estado
Unicidad	`ventas.csv`	`ID_Venta` (PK)	Se detectaron **29 registros duplicados exactos** (3.029 filas totales vs. 3.000 IDs únicos).	ALTO	Filtrado de primera aparición y consolidación de 3.000 ventas únicas en Sheets.	CORREGIDO
Completitud	Todas las tablas	Todas las columnas	**0 valores nulos o celdas vacías** en los campos clave (IDs, importes, cantidades, estados).	BAJO	Integridad estructural completa. No se requirió imputación artificial de datos.	APROBADO
Consistencia de Tipos	`productos.csv`	`Precio_Unitario`	Valores monetarios formateados como texto con coma decimal (ej. `"12,24"`).	ALTO	Conversión con `=VALOR(SUSTITUIR(...,",","."))` y formato contable `$#,##0.00`.	CORREGIDO
Consistencia Léxica	`clientes.csv`	Encabezados y Nombres	Encabezado con typo (`Fecha_Resgistro`) y espacios accidentales en nombres.	MEDIO	Normalización con `=NOMPROPIO(ESPACIOS(...))` y `=MINUSC(...)` para correos.	CORREGIDO
Integridad Relacional	`ventas` vs. `clientes`	`ID_Cliente` (FK)	**100% de coincidencia:** Los 326 clientes vinculados existen en la tabla maestra.	NULO	Validación satisfactoria. Unión relacional sin pérdidas mediante `=BUSCARV()`.	APROBADO
Integridad Relacional	`ventas` vs. `productos`	`ID_Producto` (FK)	**100% de coincidencia:** Los 38 productos transaccionados coinciden con el catálogo.	NULO	Enriquecimiento de categoría y precio maestro ejecutado sin discrepancias.	APROBADO
Validez	`ventas.csv`	`Estado`	Distribución coherente: 2.523 Completas (84.1%), 467 Pendientes (15.6%), 10 Canceladas (0.3%).	BAJO	Configuración de regla de **Validación de Datos** (lista desplegable) en el libro.	APROBADO
Exactitud	`ventas.csv`	`Cantidad`, `Fecha`	Cantidades acotadas de 1 a 6 unidades por ítem. Fechas válidas en el año 2024.	BAJO	Coherencia lógica de magnitudes comerciales para venta minorista.	APROBADO

Índice Global de Calidad de Datos (DQI): 98.5%

Tras subsanar la unicidad de transacciones y normalizar tipos numéricos, el conjunto de datos cuenta con aptitud óptima para modelado analítico y reportería en producción.

98.5%

5. MODIFICACIONES REALIZADAS SOBRE LOS SETS DE DATOS

Siguiendo el principio de **inmutabilidad de los datos crudos**, los archivos fuente originales se preservaron intactos en hojas de respaldo (`01_Raw_...`), ejecutándose todas las transformaciones de limpieza y consolidación en hojas de trabajo estructuradas en Google Sheets.

Paso 1: Preservación de la Capa de Datos Crudos (Hojas `01_Raw_...`)

Se importaron sin alteraciones los 5 conjuntos de datos transaccionales y dimensionales:

- `01_Raw_Ventas` (3.029 filas originales de transacciones brutas).
- `01_Raw_Clientes` (326 registros maestros de clientes).
- `01_Raw_Productos` (38 registros de catálogo de artículos).
- `01_Raw_MetodosPago` (5 registros de medios de cobro).
- `01_Raw_Categorias` (8 registros de familias comerciales).

Paso 2: Limpieza y Normalización Dimensional (Hoja: `02_Limpieza_Normalizacion` - Clase 5)

- **Clientes:**
  - Nombre y Apellido saneados mediante fórmula: `=NOMPROPIO(ESPACIOS('01_Raw_Clientes'!B5))` para corregir espaciado irregular y capitalización.
  - Normalización de correos electrónicos con: `=MINUSC(ESPACIOS('01_Raw_Clientes'!D5))` para garantizar uniformidad en claves de contacto.
  - Corrección del encabezado de fecha de alta a `Fecha_Registro`.
- **Productos:**
  - Conversión de precio de texto a valor numérico contable: `=VALOR(SUSTITUIR('01_Raw_Productos'!D5, ",", "."))`, aplicando formato `$#,##0.00`.
  - Eliminación de espacios residuales en descripciones de familias con `=ESPACIOS(...)`.

Paso 3: Deduplicación y Consolidación Relacional (Hoja: `03_Consolidado_Ventas` - Clase 6)

- **Deduplicación Estructural:** Se eliminaron los 29 registros duplicados de `ID_Venta`, consolidando una base depurada de **3.000 ventas únicas**.
- **Enriquecimiento Relacional con `=BUSCARV()`:**
  - **Nombre del Cliente:** `=BUSCARV(D5; '02_Limpieza_Normalizacion'!$B$7:$H$332; 2; FALSO) & " " & BUSCARV(D5; '02_Limpieza_Normalizacion'!$B$7:$H$332; 3; FALSO)`
  - **Email del Cliente:** `=BUSCARV(D5; '02_Limpieza_Normalizacion'!$B$7:$H$332; 4; FALSO)`
  - **Región Geográfica:** `=BUSCARV(D5; '02_Limpieza_Normalizacion'!$B$7:$H$332; 6; FALSO)`
  - **Nombre del Producto:** `=BUSCARV(H5; '02_Limpieza_Normalizacion'!$J$7:$O$44; 2; FALSO)`
  - **Categoría del Producto:** `=BUSCARV(H5; '02_Limpieza_Normalizacion'!$J$7:$O$44; 3; FALSO)`
  - **Precio Unitario Maestro:** `=BUSCARV(H5; '02_Limpieza_Normalizacion'!$J$7:$O$44; 4; FALSO)`
  - **Nombre del Método de Pago:** `=BUSCARV(N5; '01_Raw_MetodosPago'!$A$5:$B$9; 2; FALSO)`
- **Columnas Calculadas Incorporadas:**
  - **Mes_Año:** `=DERECHA(B5; 4) & "-" & EXTRAE(B5; 4; 2)` para posibilitar agrupamiento cronológico (AAAA-MM).
  - **Subtotal_Venta:** `=K5 * L5` (Precio Unitario × Cantidad facturada).

5. MODIFICACIONES (CONT.): ANÁLISIS ESTADÍSTICO, DASHBOARD Y CONCLUSIÓN

Paso 4: Análisis Estadístico Descriptivo (Hoja: `04_Estadistica_Descriptiva` - Clase 7)

Se procesaron las medidas de tendencia central y dispersión sobre el importe facturado de las 3.000 ventas:

MEDIA (PROMEDIO)	MEDIANA (TÍPICO)	MODA	DESV. ESTÁNDAR
$34.37	**$26.16**	**$32.70**	**$27.48**
`=PROMEDIO(...)`	`=MEDIANA(...)`	`=MODA.UNO(...)`	`=DESVEST.M(...)`

FACTURACIÓN BRUTA TOTAL	FACTURACIÓN NETA COMPLETA	RANGO DE IMPORTES
$103,103.19	**$87,729.89**	**$3.25 a $171.36**
3.000 pedidos totales	2.523 pedidos con estado Completa	Rango: $168.11 · Varianza: 755.34

Interpretación de los Hallazgos Estadísticos:

1. **Asimetría Positiva (Sesgo a la Derecha):** La Media ($34.37) supera a la Mediana ($26.16). El 50% de las ventas se sitúa por debajo de los $26.16, pero compras familiares o mayoristas de hasta $171.36 elevan el promedio. La **mediana es la medida más representativa del ticket típico**.
2. **Alta Dispersión de Compra:** La desviación de $27.48 frente a la media de $34.37 arroja un coeficiente de variación del 79.9%, reflejando marcada heterogeneidad en el volumen de compra de los consumidores.
3. **Estabilidad Mensual:** Tras el inicio en enero, la facturación se mantiene entre $8,700 y $10,285 mensuales, alcanzando su pico en **junio de 2024 ($10,285.44)** y **marzo de 2024 ($10,046.08)**.

Paso 5: Tablero de Control y Formato Condicional (Hoja: `05_Dashboard_Reporte` - Clase 8)

- **Segmentación por Categoría:** *Carnicería* lidera con $27,924.82 (27.1%), seguida de *Lácteos* ($16,093.78) y *Congelados* ($14,918.25). *Conservas* representa la menor participación ($4,864.23, 4.7%).
- **Segmentación por Medio de Pago:** Clara preferencia por cobros digitales: *Mercado Pago* concentra $30,561.97 (29.6%) y *Transferencia bancaria* $27,438.07 (26.6%).
- **Segmentación Geográfica:** *Buenos Aires* representa el 35.8% ($36,904.41), seguida por *Centro* ($20,083.17) y *Patagonia* ($18,478.97).
- **Formato Condicional:** Escalas de color continuas para rendimiento comercial y banderas de alerta visual para pedidos pendientes y cancelados.

Conclusión del Proyecto de Consultoría:
El desarrollo integral de este entregable demuestra cómo la secuencia metodológica vista en las Clases 1 a 8 (auditoría diagnóstica, normalización de datos, cruces relacionales con fórmulas de búsqueda, modelado estadístico descriptivo y diseño de tableros gerenciales) convierte microtransacciones operativas en un sistema de inteligencia de negocio confiable, escalable y preparado para la toma de decisiones estratégicas.